

LLaMA: Open and Efficient Foundation Language Models

0. 주요 내용 요약

이 논문에서는 LLaMA (Large Language Model Meta AI)라는 새로운 대형 언어 모델 시리즈를 소개합니다. LLaMA는 7B, 13B, 33B, 65B 크기의 다양한 모델을 포함하며, 공개된 데이터만을 사용하여 훈련되었다는 점에서 기존의 GPT-3, Chinchilla, PaLM과 차별화됩니다.

논문의 주요 기여는 다음과 같습니다:

- LLaMA-13B 모델이 GPT-3 (175B) 보다 우수한 성능을 보이며, LLaMA-65B는 Chinchilla-70B 및 PaLM-540B와 경쟁력이 있음.
- 훈련 데이터는 CommonCrawl, C4, Github, Wikipedia, ArXiv, StackExchange 등을 포함하여 총 1.4T 토큰 규모로 구성됨.
- Transformer 아키텍처를 최적화하여 학습 효율성을 향상시키고, RoPE (Rotary Embedding), SwiGLU 활성화 함수, RMSNorm 정규화 등의 최신 기술을 적용함.
- 제로샷 및 퓨샷 학습 벤치마크에서 기존 모델과 성능 비교.
- 모델 학습 시 에너지 소비 및 탄소 배출량 분석 제공.

1. Approach

GPT-3 방식의 Transformer 구조이나, 아래 설명하는 대로 몇 가지 원래 구조와 다르게 사용한 것이 있음

1.1 Pre-normalization [GPT3]

- stability 를 위해 각 transformer sub-layer 의 input 에 normalization 적용 (<https://arxiv.org/pdf/2002.04745.pdf>)
- input 에 normalization 적용하여 gradient vanishing 문제 해결
- 빠른 수렴 속도, 일반화 성능
- 기존 layerNorm 사용하는 것 대신 RMSNorm 을 normalizing function 으로 사용 (<https://arxiv.org/abs/1910.07467>, NeurIPS 2019)

1.2 SwiGLU activation function [PaLM]

- PaLM 에서 사용한 방법이며, GLU dimension 크기를 기존 4d 를 쓰는 것 대신 $\frac{2}{3} * 4d$ 를 사용하는 것으로 수정했다고 함

- 다양한 activation function 중 Swish function 을 사용하고, Gated Linear Units (GLU) 를 적용한 것이 [SwiGLU](#) 임
- ReLU 대신 [SwiGLU](#) 사용 (<https://arxiv.org/abs/2002.05202>, Google 2020)
 - 이는 performance 향상이 목적
 - 다양한 activation function 에 대해 FFN 에 GLU 를 적용하였을 때, 성능 향상이 있었음

1.3 Rotary Embeddings [GPTNeo]

- 아이디어 제안은 다른 논문에서 시작 되었으나 ([RoFormer: Enhanced Transformer with Rotary Position Embedding](#)), EleutherAI 에서 GPT-J 구현에 사용하여 유명해진 방법
 - RoPE 는 Relative PE 기반의 방법이고, Additive form 이 아닌 Multiplicative 기법 + Sinusoid 함수를 활용한 방법
 - Token embedding 을 complex form 으로 매핑을 하고, position 정보는 이 token embedding 을 rotation 시켜서 표현할 수 있음
- absolute positional embeddings 사용하는 것 대신 rotary positional embeddings (RoPE) 사용했다고 함
- each layer 마다 RoPE 적용

2. 실험 및 결과 분석

논문에서는 다양한 언어 모델 벤치마크를 수행하여 LLaMA 모델의 성능을 평가합니다.

(1) Common Sense Reasoning (상식 추론 성능)

- BoolQ, PIQA, SIQA, HellaSwag, WinoGrande 등의 벤치마크에서 평가.
- LLaMA-65B는 Chinchilla-70B보다 대부분의 벤치마크에서 성능이 우수.
- LLaMA-13B는 **GPT-3 (175B)**보다 10배 작지만 대부분의 벤치마크에서 뛰어난 성능을 보임.

(2) Closed-Book QA (사전 지식 기반 질문 응답)

- Natural Questions (NQ), TriviaQA 벤치마크에서 평가.
- LLaMA-65B는 **Gopher (280B), Chinchilla (70B)**와 비슷한 수준의 성능을 보임.

(3) Reading Comprehension (독해 성능)

- RACE 벤치마크에서 평가.
- LLaMA-65B는 PaLM-540B와 유사한 성능을 보이며, LLaMA-13B도 GPT-3을 능가함.

(4) Mathematical Reasoning (수학적 추론)

- MATH, GSM8k 벤치마크에서 평가.
- LLaMA-65B가 Minerva-62B보다 높은 성능을 기록했으며, 수학 데이터로 추가 학습하지 않았음에도 좋은 성과를 보임.

(5) Code Generation (코드 생성)

- HumanEval, MBPP 벤치마크에서 평가.
- LLaMA-65B는 PaLM-62B보다 우수한 코드 생성 성능을 보이며, LaMDA-137B보다도 높은 성능을 기록함.

(6) MMLU (Massive Multitask Language Understanding)

- 57개 분야의 지식을 평가하는 MMLU 벤치마크에서 LLaMA-65B는 GPT-3 및 PaLM-62B보다 우수하지만, Chinchilla-70B 및 PaLM-540B보다 약간 부족함.

(7) Instruction Fine-tuning (명령어 학습)

- Flan-PaLM, OPT-IML과 비교하여 MMLU 점수 비교.
- 간단한 명령어 학습만으로도 LLaMA-65B의 성능이 Chinchilla-70B보다 우수해짐.

3. 기술적 기여

1. 공개된 데이터만으로도 최첨단 성능을 낼 수 있음을 입증

- 기존의 GPT-3, PaLM이 비공개 데이터셋을 사용한 반면, LLaMA는 공개된 데이터만 사용함.
- 결과적으로 모델의 재현 가능성과 개방성이 높아짐.

2. 소형 모델의 성능 최적화

- LLaMA-13B가 GPT-3 (175B)보다 뛰어난 성능을 보이며, 소형 모델을 활용한 실용성 증대를 입증.
- 이는 연구 및 산업에서 더 적은 자원으로 강력한 모델을 사용할 수 있도록

록 함.

3. 아키텍처 최적화

- RoPE (Rotary Position Embeddings) 도입으로 위치 정보 표현 개선.
- SwiGLU 활성화 함수 적용으로 학습 속도 및 성능 개선.
- Pre-normalization 기법 적용으로 안정적인 학습 유도.

4. 효율적인 학습 및 탄소 배출량 고려

- 학습 과정에서 xformers 라이브러리를 활용하여 메모리 사용량 최적화 및 속도 향상.
- LLaMA-13B는 단일 GPU에서도 실행 가능하여 연구자들에게 더 많은 접근성을 제공.
- 학습 과정에서 탄소 배출량을 평가하여, 친환경적 AI 연구의 중요성을 강조.

3.1 Efficient Implementation

- casual multi-head attention 계산 시, memory/runtime 감소를 위해 별도 구현된 library 를 사용함
 - xformer library 사용
 - backward 에서는 Flashattention 사용 (<https://arxiv.org/abs/2205.14135>, 2022)
 - attention weights 를 저장하지 않고, LM task 에서 masked 되는 부분은 key/query 를 계산하지 않게끔 함
- backward pass 동안 다시 계산되는 activations 양을 줄임
 - 즉, linear layers 의 output 과 같은 계산량이 많은 activations 를 미리 저장해 놓는 방식
 - pytorch autograd 말고 직접 backward function 을 구현하였음
- Reducing activation recomputation in large transformer models (<https://arxiv.org/pdf/2205.05198.pdf>) 논문에 소개된 것 처럼 model and sequence parallelism 을 적용하여 memory usage 감소
- activation 계산과 GPU 간의 communication 을 최대한 overlap 시켜서 최적화 하였음 (all_reduce 같은 연산)

- 65B 모델의 경우, 380 tokens/sec/GPU on 2048 A100 GPU with 80GB of RAM 이고, 이를 환산하면 1.4T tokens 학습 시 21일 걸림

4. 한계점 및 향후 연구 방향

1. Bias 및 Toxicity 문제

- LLaMA 모델이 젠더, 인종, 종교적 편향을 포함할 가능성이 있음을 CrowS-Pairs 및 WinoGender 벤치마크를 통해 확인.
- RealToxicityPrompts에서 모델 크기가 증가할수록 독성이 증가하는 경향을 보임.
- 향후 bias mitigation (편향 완화) 연구가 필요함.

2. Instruction Tuning 추가 필요

- Flan-PaLM이나 GPT-4처럼 Instruction Fine-tuning을 더 적용하면 성능이 더욱 향상될 것으로 보임.
- 간단한 Instruction Tuning 실험에서는 MMLU에서 성능이 향상됨을 확인함.

3. 멀티모달 학습 부족

- 논문에서는 언어 모델만 다루고 있으며, 이미지, 영상 등과 결합한 멀티모달 학습이 포함되지 않음.
- GPT-4, Gemini, Claude 등 멀티모달 AI 경쟁 모델과 비교할 필요가 있음.

** 참고자료: <https://velog.io/@wkshin89/Paper-Review-LLaMA-Open-and-Efficient-Foundation-Language-Models>